

47

RAG Pipeline offloading
via NVMe-oF for Edge LLM Inference

소속 정보컴퓨터공학부

분과 D

팀명 오에스

참여학생 양윤성, 나예은

지도교수 안성용

과제 개요

❖ 과제 배경


- Edge Device에서 RAG를 실행할 때 corpus가 커질수록 vector index를 메모리에 모두 올리기 어려움.
- 분리형 Storage에서는 Edge와 Storage Server 사이의 네트워크를 통해 많은 데이터가 이동함.
이 과정에서 overhead 발생

❖ 과제 목표

- RAG pipeline에서 similarity search와 tokenization 단계를 Server로 offloading
- NVMe-oF와 SPDK를 사용하여 commodity hardware환경에서 구현

핵심 기술

❖ Offloading Path



1. Query 입력
2. Placeholder file 생성 및 LBA 범위 확인
3. Custom NVMe-oF Command 전송
4. Storage Server에서 RAG + Tokenization
5. Token을 지정된 LBA에 기록
6. Direct I/O로 Placeholder file read → Inference


- RAG 연산을 데이터가 위치한 Server에서 실행 → 원격 Index I/O 감소
- Tokenization까지 offloading → Edge와 Storage 간에 데이터 이동 감소
- 범용 NVMe-oF/SPDK 환경 사용 → 전용 하드웨어 불필요

실험 결과

❖ 실행 환경

Edge	Jetson Orin Nano
Vector DB	PostgreSQL (w/pgvectorscale)
Embedding	bge-m3
LLM	Gemma 3 270M (llama.cpp)
워크로드	TriviaQA
데이터베이스	7GB
네트워크 대역폭	1Gbps

❖ End-to-end latency



❖ 지연시간 분석

